Clothing Search System

Operaciones de Aprendizaje Automático II - Maestría en inteligencia artificial - UBA

Grupo N° 5

Alumnos: Barria Alex, Bureu Clara y Torti Maximiliano



Introducción y Objetivo del Proyecto

Objetivo: Evolución de sistema de búsqueda multimodal de productos de moda, bajo un enfoque MLOps.

Dominio: productos de moda, orientado a e-commerce.

Herramientas principales:

- Docker
- Apache Airflow
- Kafka
- MLflow
- Minio / S3
- PostgreSQL + pgvector
- REST / GraphQL / gRPC
- Modelo CLIP (ViT-B/32)
- Dataset Fashion Product Images (Hugging Face) [link]

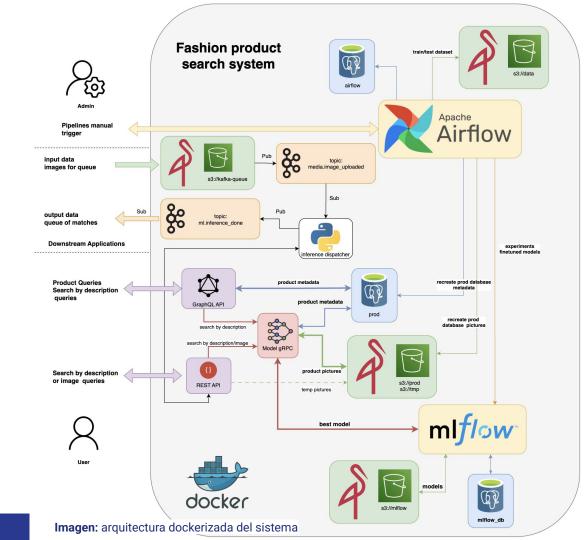
```
product = {
    "id": 15970,
    "gender": "Men",
    "masterCategory": "Apparel",
    "subCategory": "Topwear",
    "articleType": "Shirts",
    "baseColour": "Navy Blue",
    "season": "Fall",
    "year": 2011.0,
    "usage": "Casual",
    "productDisplayName": "Turtle Check Men Navy Blue Shirt",
    "image": {}
}
```

Imagen: ejemplo del contenido del dataset

Arquitectura del Sistema

Flujo general:

- ingesta de datos, procesamiento, entrenamiento de modelos y evaluación con Apache Airflow
- 2. Almacenamiento en MinIO y PostgreSQL
- 3. Versionado entrenamientos y modelo con MLflow.
- 4. Interacción con los datos y búsquedas por API Rest y GraphQL.
- 5. Procesamiento streaming basado en eventos con Kafka y MinIO



Modelo CLIP y Fine-tuning

- CLIP mapea imágenes y textos a un espacio latente compartido.
- Entrenamiento original con 400M de pares texto-imagen (OpenAI).
- Utilizamos OpenCLIP + fine-tuning sobre dataset ~1k items:
 - o 5 épocas, batch size 32, AdamW, lr = 1e-5
 - Pérdida contrastiva simétrica
 - o (GPU | 6GB RAM | 1280 cuda cores)
- Resultado: mejora en performance tras fine-tuning.

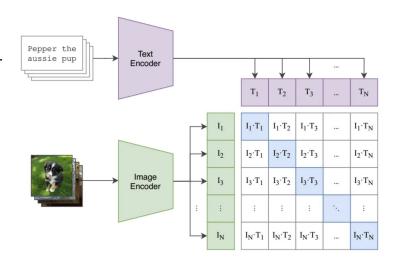


Imagen: diagrama de la arquitectura del modelo CLIP [ref]

Apache Airflow y MLflow

- 3 DAGs:
 - recreate_prod_database
 - process_train_test_dataset
 - finetune

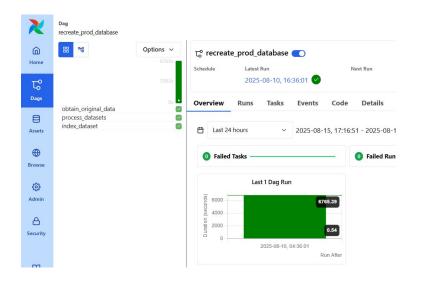
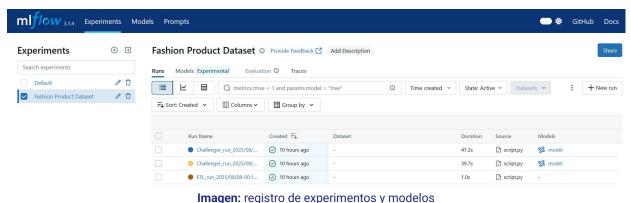
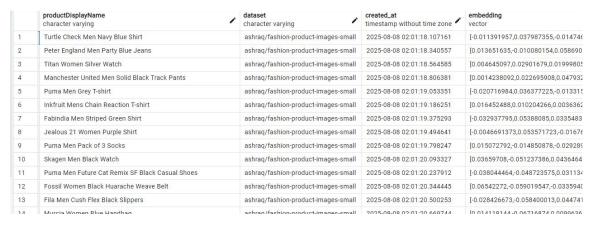


Imagen: dag en ejecución



Almacenamiento Imágenes y Metadatos

- MinIO para almacenar imágenes y datasets de entrenamiento/test.
- PostgreSQL para almacenar metadatos y embeddings.



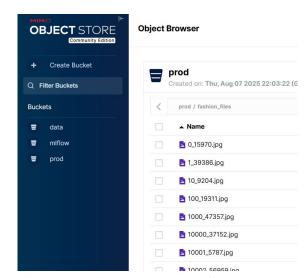


Imagen: almacenamiento de imágenes de productos

Imagen: tabla de metadatos de productos

Interacción con el sistema

- Consulta de metadatos de productos con GraphQL.
- Búsqueda de productos por texto descriptivo con GraphQL y REST.
- Búsqueda por imágenes con REST.
- Ul basada en Streamlit disponible para acelerar la integración.

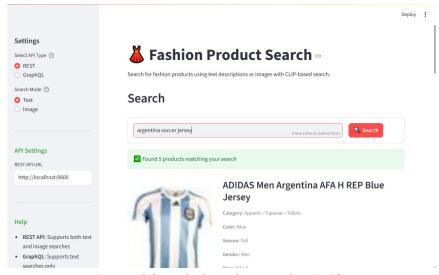


Imagen: búsqueda de producto por descripción

 Las API se comunican por gRPC con el servicio de ejecución del modelo.

Streaming con Kafka

- Disponibilidad de procesamiento streaming.
- Procesamiento basado en eventos de bucket s3.
- Tópico de salida disponibiliza los datos para procesos posteriores.

```
Problems 275
                        Debug Console
inference dispatcher-1
                          --> Waiting for message...
                                                                      rest api
                                                                                             127.0.0.1:60944 - "GET / HTTP/1.1" 200 OK
inference_dispatcher-1
                          --> Waiting for message...
                                                                      rest_api
                                                                                   INFO:
                                                                                             127.0.0.1:43232 - "GET / HTTP/1.1" 200 OK
inference dispatcher-1
                          --> Waiting for message...
                                                                      rest_api
                                                                                   INFO:
                                                                                             127.0.0.1:50138 - "GET / HTTP/1.1"
                                                                                   INFO:
                                                                                             127.0.0.1:59466 - "GET / HTTP/1.1"
inference dispatcher-1
                          --> Waiting for message...
                                                                      rest_api
inference dispatcher-1
                          --> Waiting for message...
                                                                      rest api
                                                                                   INFO:
                                                                                             127.0.0.1:47530 - "GET / HTTP/1.1" 200 OK
                          --> Waiting for message...
inference_dispatcher-1
                                                                      rest_api
                                                                                   INFO:
                                                                                             127.0.0.1:51682 - "GET / HTTP/1.1" 200 OK
inference dispatcher-1
                                                                                   INFO:
                                                                                             127.0.0.1:53964 - "GET / HTTP/1.1" 200 OK
                          --> Waiting for message...
                                                                      rest_api
inference dispatcher-1
                                                                                             127.0.0.1:54832 - "GET / HTTP/1.1" 200
                          --> Waiting for message...
                                                                      rest api
                                                                                             127.0.0.1:49324 - "GET / HTTP/1.1" 200 0K
inference_dispatcher-1
                          --> Waiting for message...
                                                                      rest_api
                                                                                   INFO:
                                                                                             127.0.0.1:53916 - "GET / HTTP/1.1"
                                                                      rest_api
                                                                                   INFO:
                          --> Successfully processed and produce
                                                                                   INFO:
inference dispatcher-1
                                                                       rest api
                                                                                             127.0.0.1:35638 - "GET / HTTP/1.1" 200
d message for key: 78_49653.jpg
                                                                                   INFO:
                                                                                             127.0.0.1:48494 - "GET / HTTP/1.1" 200 OK
                                                                      rest_api
inference dispatcher-1
                          --> Waiting for message...
                                                                      rest_api
                                                                                   INFO:
                                                                                             127.0.0.1:46806 - "GET / HTTP/1.1" 200
inference dispatcher-1
                          --> Waiting for message...
                                                                      rest api
                                                                                             127.0.0.1:50798 - "GET / HTTP/1.1"
                                                                                             127.0.0.1:49852 - "GET / HTTP/1.1" 200 OK
inference dispatcher-1
                          --> Waiting for message...
                                                                      rest api
inference dispatcher-1
                          --> Waiting for message...
                                                                       rest api
                                                                                   INFO:
                                                                                             127.0.0.1:58482 - "GET / HTTP/1.1" 200 OK
inference dispatcher-1
                          --> Waiting for message...
inference dispatcher-1
                                                                                  INFO:root:Received prediction request for S3 object:
                          --> Waiting for message...
inference_dispatcher-1
                          --> Waiting for message...
                                                                       kafka-queue/78_49653.jpg
inference_dispatcher-1
                          --> Waiting for message...
                                                                       rest_api | INFO:app:gRPC response received for S3 object: kafka
inference dispatcher-1
                          --> Waiting for message...
                                                                       -queue/78_49653.jpg
inference dispatcher-1
                          --> Waiting for message...
                                                                                             172.19.0.13:37466 - "POST /predict HTTP/1.
                                                                       rest api
inference dispatcher-1
                          --> Waiting for message...
                                                                      1" 200 OK
```

Imagen: logs al momento de recibir una nueva imágen

```
{
    "bucket": "kafka-queue",
    "key": "78_49653.jpg",
    "eTag": "a927efec534e0c4a3eeaf845acfc5371",
    "status": "OK",
    "results": [
    {
        "id": 79,
        "filename": "78_49653.jpg",
        "s3_path": "fashion_files/78_49653.jpg",
        "masterCategory": "Apparel",
        "subCategory": "Topwear",
        "articleType": "Tops",
        "haseColour": "Green"
```

Imagen: ejemplo del tópico de salida

Análisis y Conclusiones

- Transición del sistema a una arquitectura MLOps dockerizada permite escalabilidad, reproducibilidad y trazabilidad:
 - Pipelines complejos automatizados.
 - Despliegues automáticos y versionados de datos y modelos.
 - Ecosistema robusto con integración a herramientas actuales estándar en la industria.
- Se abren nuevas oportunidades de mejora como incorporar mecanismos de retraining automático con la llegada de nuevos datos o explorar estrategias de feedback humano

Demo

Gracias por su atención ¿Preguntas?